

Sistema de Detección de Colisiones Vehiculares por Visión de Computadora

Ramirez Montaña, Andres Felipe
Universidad Nacional de Colombia
Departamento de Ingeniería de Sistemas e Industrial
andramirez@unal.edu.co

I. RESUMEN.

Para nadie es un secreto que el tráfico vehicular es una de las problemáticas estructurales que enfrentan cada día las ciudades, debido al crecimiento del parque automotor y mala gestión tanto en la seguridad y el monitoreo del mismo. En este documento se quiere presentar un sistema de detección de colisiones vehiculares usando inteligencia artificial, más específicamente la técnica de visión por computadora. El sistema analiza secuencias de video para identificar vehículos, mirar las trayectorias de las mismas y detectar colisiones a través de modelos de aprendizaje automático y patrones visuales. Como objetivo principal es ayudar a la planeación y gestión de la estructura vial, ya que al usar estadísticas con más accidentes será un punto de quiebre para tratar de mejorar y avanzar con el problema que influye cada día en la vida de las personas.

Palabras clave: Visión por computadora, colisión vehicular, monitoreo, seguridad, aprendizaje automático, inteligencia artificial.

Abstract— It is no secret that vehicular traffic is one of the structural problems that cities face every day, due to the growth of the vehicle fleet and poor management in both safety and monitoring. In this paper we want to present a vehicle collision detection system based on the computer vision technique. The system analyzes video sequences to identify vehicles, look at their trajectories and detect collisions through machine learning models and visual patterns. The main objective is to help the planning and management of the road structure, since using statistics with more accidents will be a break point to try to improve and move forward with the problem that influences people's lives every day.

Keywords— Computer vision, vehicle collision, monitoring, safety, machine learning, artificial intelligence.

II. INTRODUCCIÓN

En los últimos años, los sistemas de predicción/advertencia de colisiones en vehículos han adquirido cada vez mayor importancia para mejorar la seguridad vial. Estos sistemas pueden predecir colisiones inminentes y alertar a los conductores, dándoles tiempo para reaccionar y potencialmente evitar un accidente. Por lo tanto, se han convertido en una parte integral de los sistemas avanzados de asistencia al conductor [1].

En los últimos años, las técnicas de aprendizaje profundo han mejorado notablemente la visión por computadora hasta un nivel que casi alcanza las capacidades humanas en la percepción visual. Por lo tanto, no es sorprendente que los sistemas modernos de advertencia de colisión hayan adoptado técnicas de visión por computadora basadas en aprendizaje profundo [1]. Para este caso se pueden utilizar algunas herramientas tecnológicas que ya vienen con modelo preentrenados para detección de objetos como YOLO y análisis de tráfico [2] y detección de patrones importantes utilizando librerías como OpenCV utilizando el lenguaje de programación Python.

Ahora, con las causas de accidentes puede recurrir tanto a los errores humanos como la somnolencia, fatiga vial o algunas distracciones, pero hay que tener en cuenta que las condiciones viales y ambientales también pueden causar accidentes de tránsito. Entre estos últimos se incluyen la falta de alumbrado público y las condiciones climáticas, como la niebla y la lluvia, que reducen la visibilidad y hacen que las carreteras sean resbaladizas. En estos casos, intervienen múltiples variables, tanto psicológicas como físicas. Factores como la falta de atención, la fatiga y el comportamiento inmaduro del conductor son algunas de las principales causas de accidentes de tránsito [3]. Según la Administración Nacional de Seguridad del Tráfico en las Carreteras (NHTSA), casi el 25 % de los accidentes reportados a la policía implican algún tipo de falta de atención del conductor: el conductor está distraído, fatigado, dormido o absorto en sus pensamientos [4]. Casi el 50 % de los accidentes que involucran falta de atención se deben a la distracción del conductor [4], [5].

En este artículo se propone el desarrollo de un sistema computacional capaz de utilizar algoritmos de detección y monitoreo para identificar patrones relacionados con colisiones vehiculares. La solución se basa en técnicas de procesamiento y análisis de imágenes, combinadas con mecanismos de almacenamiento de datos, con el objetivo de establecer una infraestructura inteligente para la gestión del tráfico mediante visión por computadora.

III. TRABAJOS RELACIONADOS

La aplicación de la inteligencia artificial en diversos sectores, como la reducción del impacto de los accidentes en las carreteras colombianas, busca ofrecer una herramienta específica, actualizada y precisa para detectar choques de manera exacta. Esto tiene como objetivo aumentar las probabilidades de una respuesta rápida por parte de los servicios de emergencia, acortar los tiempos de atención, prevenir consecuencias más graves y, al final del

día, salvar vidas. Además, esta herramienta puede proporcionar información valiosa para analizar y mejorar la seguridad vial, optimizando así la toma de decisiones en el ámbito institucional y gubernamental.

En la revista Y. Xu et al., "TAD: A Large-Scale Benchmark for Traffic Accidents Detection From Video Surveillance" [9] proponen unos algoritmos para hacer el monitoreo del tráfico donde según este artículo se proponen como:

- **Algoritmo de clasificación**
- **Algoritmo de detección de objetos**

Donde estos son los más populares para detectar objetos que poseen tanto como una formación o una posición característica en las imágenes de entrenamiento. Por ejemplo, el algoritmo de clasificación funciona como un clasificador binario para distinguir entre imágenes que contienen vehículos dañados como clase positiva y no como clase negativa y con respecto al algoritmo de detección de objetos se tiene que YOLOv4 posee más precisión con respecto la detección de objetos bajo condiciones climáticas fuertes. Además, con la llegada de YOLOv9 refina más la infraestructura y procedimientos de entrenamiento y también aprovecha el escalado del modelo, la detección sin anclas y las estrategias de entrenamiento mejoradas para lograr mejores resultados en varios puntos de referencia.

Por otro lado, en otro documento [11] se centra en técnicas previas para la detección y predicción de accidentes de tráfico, basadas principalmente en el seguimiento de vehículos mediante procesamiento de vídeo y análisis de trayectorias. Estas técnicas incluyen métodos clásicos como la detección de movimiento por diferencia entre frames y el uso de filtros de Kalman para predecir movimientos futuros. También se mencionan enfoques basados en modelos geométricos 3D que permiten estimar la posición y orientación de los vehículos para calcular posibles intersecciones de trayectoria. Otra línea abordada es el uso de redes neuronales autoorganizadas, especialmente el tipo Kohonen y sus variantes difusas, con el fin de agrupar y aprender patrones de comportamiento vehicular. Para la predicción de colisiones, se usan cálculos probabilísticos que combinan la probabilidad de que dos vehículos pertenezcan a ciertos patrones de movimiento y la probabilidad condicional de colisión entre ellos, ajustada temporalmente mediante una función gaussiana. Algunos trabajos también aplican análisis de distancia entre puntos críticos de las trayectorias para identificar riesgos inminentes. En general, los enfoques revisados integran técnicas de visión artificial, modelado espacial y razonamiento probabilístico para mejorar la capacidad de anticipación ante eventos anómalos o accidentes en entornos de tráfico complejos.

La metodología presentada en el artículo se enfoca en un sistema para detectar y analizar accidentes de tráfico a través del análisis de video de vigilancia. Combina técnicas de detección de objetos, seguimiento de vehículos y análisis de patrones en el tiempo y el espacio. Aquí tienes un resumen más claro:

El sistema inicia con la detección de vehículos usando el modelo YOLO v3, que permite identificar rápidamente los

vehículos en la escena. Este paso es crucial para localizar los vehículos que podrían estar involucrados en un accidente. Luego, se lleva a cabo un análisis del movimiento basado en la trayectoria antes de la colisión. Para esto, se utiliza una técnica de agrupamiento jerárquico que ayuda a recuperar las trayectorias completas de los vehículos antes del evento.

Una vez que se obtienen las trayectorias, el sistema examina patrones de movimiento inusuales y calcula la probabilidad de que ocurra un accidente. Este análisis incluye la comparación entre secuencias normales y atípicas, lo que ayuda a diferenciar entre eventos accidentales y situaciones cotidianas. Además, el sistema no requiere hardware especializado ni GPU, lo que lo hace eficiente y viable para su implementación en tiempo real.

En términos de rendimiento, el sistema supera a los métodos que se basan únicamente en aprendizaje profundo, logrando una mayor precisión y una menor tasa de falsas alarmas (FAR), especialmente en situaciones donde otros modelos suelen fallar. Esto se debe a la combinación de estrategias clásicas de procesamiento de video con técnicas avanzadas de agrupamiento y detección temprana de anomalías.

En resumen, la metodología combina la detección rápida de vehículos con YOLOv3, la reconstrucción de trayectorias mediante agrupamiento jerárquico y el análisis de patrones para identificar accidentes, logrando un balance entre precisión y eficiencia sin necesidad de recursos computacionales costosos.

En [13] se presentan algoritmos de visión artificial para monitorear intersecciones viales, enfocándose en la detección y seguimiento de vehículos. Usa técnicas como sustracción de fondo, calibración de cámaras y modelos geométricos simples para estimar posición y movimiento. El sistema gestiona oclusiones con elipses de confianza y emplea filtrado de Kalman para predecir trayectorias. También incluye un módulo de detección de incidentes basado en análisis de comportamiento anómalo. Es eficiente, computacionalmente, viable para implementación en tiempo real y útil tanto para gestión de tráfico como para detección temprana de eventos críticos.

IV METODOLOGÍA

La predicción y detección de accidentes de tráfico son de suma importancia para mejorar la seguridad vial global, en línea con los objetivos de reducir significativamente las muertes y lesiones relacionadas con el tráfico para 2030 [14]. La Anticipación de Accidentes de Tráfico Basada en Visión (Visión-TAA) ha surgido como un enfoque muy prometedor en la era del aprendizaje profundo, ofreciendo una alternativa robusta a los métodos tradicionales.

El aprendizaje profundo, con su capacidad para aprender representaciones complejas directamente de los datos, ha permitido a los sistemas Visión-TAA procesar escenarios de tráfico del mundo real, incluidas condiciones de iluminación variables, múltiples agentes interactuantes y sutiles señales previas a la colisión, con una eficacia y robustez mucho mayores. Este avance representa una transformación fundamental de los modelos estadísticos o

basados en reglas más simples a redes neuronales altamente adaptables y basadas en datos.

Las metodologías actuales en Visión-TAA se categorizan ampliamente en cuatro enfoques clave, lo que refleja la creciente complejidad de la comprensión de accidentes:

- **Predicción Basada en Características de Imagen y Video:** Este enfoque fundamental se centra en la extracción de características visuales explícitas y patrones de imágenes individuales o secuencias de fotogramas de vídeo mediante operaciones como la convolución, preservando las jerarquías espaciales desde características de bajo nivel hasta características semánticas de alto nivel [14].
- **Predicción Basada en Características Espacio Temporales:** Basándose en la extracción de características, este método analiza fotogramas secuenciales para capturar tanto la información espacial como la dinámica temporal [14].
- **Comprensión de Escenas:** Este enfoque avanzado busca una comprensión profunda de los objetos y sus complejas relaciones dentro de las escenas de tráfico. Trasciende las características visuales explícitas al extraer información semántica, destacando en la captura de información organizada en escenarios complejos. Sin embargo, enfrenta desafíos debido al requisito de grandes cantidades de datos etiquetados y arquitecturas de modelos sofisticadas, lo que puede limitar la generalización a entornos diversos [14].
- **Fusión de Datos Multimodales:** Para superar las limitaciones de depender de una única fuente de datos, este enfoque combina información de varias modalidades, como video, datos de sensores (por ejemplo, GPS, IMU) y datos ambientales (por ejemplo, clima). Esta fusión mejora significativamente tanto la precisión como la robustez de las predicciones al compensar las deficiencias de las fuentes de datos individuales [14].

Utilizando uno de los modelos que más se acerca al objetivo del sistema computacional se puede usar redes neuronales Convolucionales (CNNs).

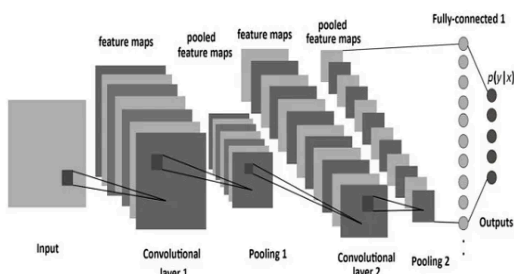


Figura 1. Modelo gráfico de CNNs [15]

Para el marco de detección de objetos y utilizando la metodología explicada anteriormente se propone el siguiente marco:

Single Shot Detector (SSD): SSD es un marco de detección de objetos diseñado para detectar múltiples candidatos a objetos y sus clases en una sola pasada hacia adelante a través de la red. En los sistemas Visión-TAA, SSD se utiliza para el monitoreo en tiempo real de participantes del tráfico como vehículos y peatones, proporcionando datos para la predicción de accidentes.

You Only Look Once (YOLO): YOLO es un algoritmo de detección de objetos altamente eficiente y preciso. Divide la imagen de entrada en una cuadrícula, y cada celda de la cuadrícula es responsable de detectar objetos dentro de sus límites y predecir tanto su posición como su clase. Una ventaja clave de YOLO es su capacidad para realizar todas las predicciones simultáneamente en una sola pasada de red, lo que lo hace excepcionalmente rápido en comparación con los detectores de múltiples etapas.

La consistencia con la que se destaca a YOLO por su velocidad y precisión y sus capacidades de tiempo de monitoreo subraya su posición dominante. La explicación de **You Only Look Once** revela la razón arquitectónica de su velocidad, procesando la imagen completa en una sola pasada. Esta fuerte conexión causal entre su diseño y su rendimiento en tiempo real lo convierte en la opción preferida para aplicaciones como la detección de accidentes, donde la respuesta inmediata y la baja latencia son fundamentales. A pesar de la existencia de otros modelos de detección de objetos, la eficiencia de YOLO y su continua evolución lo establecen como un marco altamente práctico y ampliamente adoptado para el despliegue en sistemas de seguridad de tráfico en tiempo real, especialmente en dispositivos de borde con recursos limitados o en soluciones basadas en la nube que requieren alertas rápidas. Su desarrollo continuo asegura su relevancia como una solución líder en detección de objetos en tiempo real.

V DISEÑO, DESARROLLO E IMPLEMENTACIÓN

El desarrollo de un sistema de detección de colisiones vehiculares mediante visión por computadora, utilizando **YOLO (You Only Look Once)** y **OpenCV en Python**, se estructura en varias fases clave. El objetivo es crear una herramienta eficiente y una herramienta para la atención en el tráfico del territorio y la gestión de la seguridad vial, como se ha planteado en los objetivos del proyecto.

A. Arquitectura del Sistema

El sistema propuesto seguirá una arquitectura modular para facilitar su desarrollo, mantenimiento y escalabilidad. Los componentes principales son:

1. Módulo de Captura de Video: Encargado de adquirir secuencias de video de cámaras de vigilancia existentes (CCTV, cámaras de tráfico).

2. Módulo de Detección de Objetos: Utilizará un modelo de aprendizaje profundo (YOLO) para identificar y localizar vehículos en cada fotograma del video.

3. Módulo de Seguimiento de Objetos: Mantendrá un registro de la identidad y la trayectoria de cada vehículo detectado a lo largo de múltiples fotogramas.

4. Módulo de Análisis de Comportamiento y Detección de Colisiones: Analizará las trayectorias y el comportamiento de los vehículos para identificar patrones que indiquen una colisión o un riesgo inminente.

5. Módulo de Notificación y Almacenamiento: Generará alertas en tiempo real y almacenará datos relevantes sobre los incidentes detectados.

En la siguiente figura se pueden apreciar ciertos pasos para el objetivo final del proyecto.

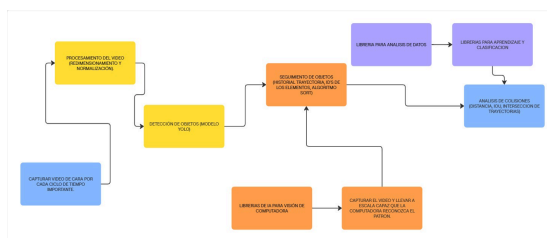


Figura 2. Flujo del programa.

B. Flujo de Implementación Teórico

El desarrollo sigue un ciclo iterativo, pero se pueden distinguir fases principales:

1. Configuración del Entorno: Implica la preparación del software base: instalación de Python, configuración de un entorno virtual para aislar dependencias, e instalación de las bibliotecas clave como **OpenCV** (para manipulación de imágenes y video) y **Ultralytics** (para la integración de modelos YOLO). También se descargan los **modelos YOLO pre-entrenados** necesarios.

2. Desarrollo del Módulo de Visión (Detección y Seguimiento):

- Se implementa la lógica para cargar el flujo de video y procesar cada fotograma.

- Se integra el modelo YOLO para la detección de vehículos, asegurándose de filtrar las detecciones irrelevantes (por baja confianza o clases no deseadas).

- Se integra el algoritmo de seguimiento (SORT) para asociar las detecciones a IDs únicas y construir las trayectorias individuales de los vehículos.

3. Desarrollo del Módulo de Lógica de Colisión:

- Se implementan los algoritmos de comparación entre pares de vehículos rastreados para calcular la superposición de sus bounding boxes (IOU) y sus distancias.

- Se definen y ajustan los umbrales de IOU y el número de fotogramas consecutivos de proximidad para declarar una colisión.

- Se considera la lógica para detectar cambios drásticos en la velocidad o dirección de los vehículos involucrados.

4. Desarrollo del Módulo de Salida y Registro:

- Se implementan los mecanismos para generar alertas claras cuando se detecta una colisión.

- Se desarrolla la funcionalidad para almacenar la información de los incidentes en una estructura de datos (ej., base de datos) y guardar los fotogramas o fragmentos de video relevantes como evidencia.

5. Pruebas y Optimización:

- El sistema se prueba exhaustivamente con diversos **conjuntos de datos de video** (incluyendo grabaciones reales de tráfico y, si es posible, datasets específicos de accidentes como **TU-DAT**).

- Se evalúa el rendimiento utilizando **métricas clave** como **Precision, Recall, F1-score, y mAP** para la detección, y **Tasa de Falsos Positivos (FAR) y Tasa de Detección (DR)** para la identificación de colisiones.

- Se ajustan los parámetros (umbrales, configuraciones del rastreador) para mejorar la robustez y reducir las falsas alarmas, especialmente en condiciones difíciles como baja visibilidad.

VI DISCUSIÓN DE RESULTADOS

Ya después de haber entrenado el modelo, utilizando las tecnologías mencionadas anteriormente, se tienen los siguientes resultados:



Figura 3. Resultados




Figura 3. Matriz de confusión.

La matriz de confusión presentada visualiza el rendimiento de un modelo de clasificación diseñado para distinguir entre "accident" (accidente), "vehicle" (vehículo) y "background" (fondo). En términos de aciertos, el modelo clasifica correctamente 175 casos como "accident", 429 como "vehicle" y tiene un alto número de aciertos para "background". Sin embargo, la matriz revela importantes áreas de mejora: 66 accidentes reales fueron erróneamente clasificados como fondo, y 23 como vehículos, lo que indica una dificultad en la detección completa de incidentes. Además, 341 vehículos fueron confundidos con el fondo, y 268 elementos del fondo fueron incorrectamente etiquetados como vehículos, evidenciando una notable confusión entre los objetos de interés y el entorno, y sugiriendo la necesidad de ajustar el modelo para mejorar la discriminación de características entre las clases.

A continuación se presenta unas imágenes sobre el test real cuando se llegue a implementar sobre las vías en Colombia.




Figura 5.



Figura 6.




Figura 7.

Es importante recalcar que los niveles de confianza en las imágenes representa un buen indicio de que el modelo predice bien los accidentes, pero hay momentos donde falla con la detección de objetos presentes en la imagen.

VII CONCLUSIONES

- Los errores de confusión, especialmente entre objetos de interés (vehículos, accidentes) y el fondo, indican que la variabilidad y la calidad de las anotaciones en el dataset de entrenamiento son cruciales. Un dataset robusto debe cubrir una amplia gama de escenarios, condiciones de iluminación, ángulos de cámara y, fundamentalmente, mostrar los objetos de forma clara y consistente para que el modelo aprenda a diferenciarlos del entorno.

- El tráfico vehicular y los accidentes son fenómenos dinámicos y complejos. Un modelo de IA no solo debe identificar objetos, sino también comprender sus interacciones, comportamientos atípicos y cambios sutiles que preceden o constituyen un accidente. Esto implica la necesidad de modelos capaces de procesar información espaciotemporal, no solo fotogramas estáticos.
- Dado que estos sistemas tienen el potencial de salvar vidas o, por el contrario, ponerlas en riesgo si fallan, la validación rigurosa, la transparencia sobre las limitaciones del modelo y una continua evaluación en entornos reales son indispensables. No se trata solo de un problema técnico, sino también de responsabilidad social y confianza pública.
- La alta confusión entre "vehículo" y "fondo", y viceversa, indica que el modelo a menudo no está **suficientemente seguro** de sus predicciones para estas clases, o que hay una superposición significativa en las características que utiliza para definir las. Esto se traduce en predicciones con niveles de confianza intermedios que, al final, resultan en clasificaciones erróneas. Abordar esto requiere mejorar la capacidad del modelo para extraer características distintivas y aumentar la confianza en sus predicciones correctas.

REFERENCIAS

- [1] C. Chitraranjan, V. Vipulanathan, y T. Sritharan, «Vision-Based Collision Warning Systems with Deep Learning: A Systematic Review», *Journal Of Imaging*, vol. 11, n.º 2, p. 64, feb. 2025, doi: 10.3390/jimaging11020064.
- [2] Y. Sui, S. Zhou, Z. Ju and H. Zhang, "A Vision-Based System Design and Implementation for Accident Detection and Analysis via Traffic Surveillance Video," in *IEEE Canadian Journal of Electrical and Computer Engineering*, vol. 45, no. 2, pp. 171-181, Spring 2022, doi: 10.1109/ICJECE.2022.3154294.
keywords: {Accidents;Trajectory;Surveillance;Computational modeling;Estimation;Cameras;Artificial intelligence;Accident detection;speed estimation;target tracking;unbiased finite impulse response (UFIR) filter;vehicles},
- [3] A. Mukhtar, L. Xia and T. B. Tang, "Vehicle Detection Techniques for Collision Avoidance Systems: A Review," in *IEEE Transactions on Intelligent Transportation Systems*, vol. 16, no. 5, pp. 2318-2338, Oct. 2015, doi: 10.1109/TITS.2015.2409109.
keywords: {Vehicles;Laser radar;Radar tracking;Vehicle detection;Roads;Cameras;Driver assistance system (DAS);motorcycle detection;sensors;tracking;vehicle detection;Driver assistance system (DAS);motorcycle detection;sensors;tracking;vehicle detection},
- [4] T. A. Ranney, E. Mazzae, R. Garrott, and M. J. Goodman, "Driver distraction research: Past, present, and future," *Transp. Res. Center Inc., East Liberty, OH, USA*, Jul. 2000.
- [5] J. D. Lee, K. L. Young, and M. A. Regan, "Defining driver distraction (Chapter 3)," in *Driver distraction: Theory, Effects and Mitigation*, ed. Boca Raton, FL, USA: CRC Press, 2008, p. 672.
- [6] S. K. Gehrig and F. J. Stein, "Collision Avoidance for Vehicle-Following Systems," in *IEEE Transactions on Intelligent Transportation Systems*, vol. 8, no. 2, pp. 233-244, June 2007, doi: 10.1109/TITS.2006.888594.
keywords: {Collision avoidance;Remotely operated vehicles;Vehicle dynamics;Intelligent vehicles;Adaptive systems;Programmable control;Adaptive control;Control systems;Navigation;Actuators;Computer vision;intelligent vehicle;robotics;stereo vision}.
- [7] S. Atev, H. Arumugam, O. Masoud, R. Janardan and N. P. Papanikolopoulos, "A vision-based approach to collision prediction at traffic intersections," in *IEEE Transactions on Intelligent Transportation Systems*, vol. 6, no. 4, pp. 416-423, Dec. 2005, doi: 10.1109/TITS.2005.858786.
keywords: {Road accidents;Traffic control;Real time systems;Hidden Markov models;Intelligent transportation systems;Testing;Video sequences;Automotive engineering;Road vehicles;Vehicle detection;Collision prediction;machine vision;real-time systems;tracking;traffic control (transportation)},
- [8] M. Kilicarslan and J. Y. Zheng, "Predict Vehicle Collision by TTC From Motion Using a Single Video Camera," in *IEEE Transactions on Intelligent Transportation Systems*, vol. 20, no. 2, pp. 522-533, Feb. 2019, doi: 10.1109/TITS.2018.2819827.
keywords: {Cameras;Roads;Radar tracking;Tracking;Merging;Vehicles;ADAS;TTC;collision avoidance;driving video;computer vision;motion profile;spatial-temporal filtering},
- [9] Y. Xu et al., "TAD: A Large-Scale Benchmark for Traffic Accidents Detection From Video Surveillance," in *IEEE Access*, vol. 13, pp. 2018-2033, 2025, doi: 10.1109/ACCESS.2024.3522384.
keywords: {Accidents;Benchmark testing;Video surveillance;Feature extraction;Classification algorithms;YOLO;Visualization;Cameras;Traffic control;Prediction algorithms;Traffic accidents;large-scale;surveillance cameras;open-sourced},
- [10] V. A. Adewopo and N. Elsayed, "Smart City Transportation: Deep Learning Ensemble Approach for Traffic Accident Detection," in *IEEE Access*, vol. 12, pp. 59134-59147, 2024, doi: 10.1109/ACCESS.2024.3387972.
keywords: {Accidents;Road traffic;Smart cities;Traffic control;Feature extraction;Computer architecture;Cameras;Traffic control;Autonomous vehicles;Deep learning;Traffic surveillance;accident detection;action recognition;smart city;autonomous transportation;deep learning},
- [11] Weiming Hu, Xuejuan Xiao, D. Xie, Tieniu Tan and S. Maybank, "Traffic accident prediction using 3-D model-based vehicle tracking," in *IEEE Transactions on Vehicular Technology*, vol. 53, no. 3, pp. 677-694, May 2004, doi: 10.1109/TVT.2004.825772.
keywords: {Road accidents;Predictive models;Remotely operated vehicles;Intelligent vehicles;Traffic control;Trajectory;Surveillance;Road vehicles;Intelligent systems;Telecommunication traffic},
- [12] Y. Sui, S. Zhou, Z. Ju and H. Zhang, "A Vision-Based System Design and Implementation for Accident Detection and Analysis via Traffic Surveillance Video," in *IEEE Canadian Journal of Electrical and Computer Engineering*, vol. 45, no. 2, pp. 171-181, Spring 2022, doi: 10.1109/ICJECE.2022.3154294.
keywords: {Accidents;Trajectory;Surveillance;Computational modeling;Estimation;Cameras;Artificial intelligence;Accident detection;speed estimation;target tracking;unbiased finite impulse response (UFIR) filter;vehicles},
- [13] H. Veeraraghavan, O. Masoud and N. P. Papanikolopoulos, "Computer vision algorithms for intersection monitoring," in *IEEE Transactions on Intelligent Transportation Systems*, vol. 4, no. 2, pp. 78-89, June 2003, doi: 10.1109/TITS.2003.821212.

keywords: {Computer vision;Computerized monitoring;Tracking;Filtering;Visualization;Road accidents;Robustness;Cameras;Calibration;Motion detection},

[14] Y. Zhang, W. Zhou, R. Lin, X. Yang, and H. Zheng, "Deep Learning Advances in Vision-Based Traffic Accident Anticipation: A Comprehensive Review of Methods, Datasets, and Future Directions," *arXiv e-print*, Art. no. arXiv:2505.07611, May 2025.

[15] Marcosesparzaarizpe, «Clasificación de imágenes con redes convolucionales.», *Medium*, 1 de diciembre de 2022. [En línea]. Disponible en: <https://medium.com/@marcosesparzaarizpe/clasificaci%C3%B3n-de-im%C3%A1genes-con-redes-convolucionales-ee98a7dd7697>.

Anexos:

GitHub: https://github.com/Andres-cmk/vehicle_collision_detection.git